

Balanceo de carga y escalado automático


El mismo punto único de fallo, resuelto de verdad

Cualquier aplicación desplegada sobre una única instancia tiene el mismo punto único de fallo: si esa instancia se cae, se cae la aplicación entera.

Hoy resuelves justo ese punto — no añadiendo «una instancia más por si acaso», sino un mecanismo que reparte el tráfico entre varias copias y repone automáticamente la que falle.

Balanceador de carga: nunca hablas con una instancia

El cliente nunca habla directamente con una instancia concreta — habla con el balanceador, y es él quien decide a cuál mandar cada petición. Hoy usas el ALB (Application Load Balancer), pensado para tráfico HTTP/HTTPS.



Listener, grupo de destino y comprobación de salud

- **Listener:**

regla del balanceador — «todo lo que llegue por el puerto 443 en HTTPS, mándalo a este grupo de destino». Puede haber varios a la vez.

- **Grupo de destino (Target Group):**

el conjunto de instancias detrás del balanceador.

- **Comprobación de salud (Health Check):**

petición HTTP periódica a una ruta concreta que debe responder correctamente para seguir recibiendo tráfico.


Por qué la comprobación de salud importa

Imagina una instancia que sigue «encendida» pero cuya aplicación se ha colgado — responde al ping de red, pero no sirve ninguna página. Sin comprobación de salud, el balanceador seguiría mandándole tráfico igualmente.

Con la comprobación activa, el balanceador la retira del grupo de destino en cuanto deja de responder, y solo la vuelve a incluir cuando se recupera.

El grupo de seguridad cambia con el balanceador delante

Ya no tiene sentido que el puerto de la aplicación siga abierto a 0.0.0.0/0: el puerto de la aplicación solo acepta tráfico desde el grupo de seguridad del propio balanceador, y es el balanceador el único con su puerto abierto a internet.



Retirar una instancia sin cortar en seco

El retraso de anulación de registro (deregistration delay) deja de mandar peticiones nuevas a una instancia retirada, pero espera a que termine las que ya tenía en curso — sin ese margen, un usuario a mitad de petición vería la conexión cortada de golpe.

AWS exige al menos dos subredes en dos zonas de disponibilidad para crear el ALB: el propio balanceador es un servicio distribuido, para no convertirse él mismo en el punto único de fallo.


Escalado vertical frente a horizontal

	Vertical	Horizontal
Qué haces	Cambias la instancia por un tipo más grande	Añades más instancias iguales
Límite	El tamaño de instancia más grande que existe	Prácticamente ninguno
¿Corte de servicio?	Sí — normalmente hay que parar la instancia	No, si está bien orquestado
Encaja con balanceador	No lo necesita	Es la base de todo lo de hoy

El escalado horizontal es el que hace posible la alta disponibilidad: con varias instancias más pequeñas repartidas, la caída de una no tumba el servicio.

Grupos de escalado automático (ASG)

Un ASG mantiene un número de instancias saludables detrás del balanceador, añadiendo o quitando automáticamente según haga falta. Se define con tres números:



El ASG necesita una plantilla de lanzamiento (Tema 2) — sin ella no sabría con qué imagen y configuración lanzar una instancia nueva.

Dos capas de comprobación de salud

	Comprobación EC2 (por defecto)	Comprobación del grupo de destino
Qué mira	Estado del hardware y la red	Respuesta HTTP de la propia aplicación
Detecta	Instancia parada o con fallo de host	Aplicación colgada, aunque esté «viva»
Quién la aporta	El propio servicio EC2	El balanceador de carga

Con las dos activas, el ASG detecta tanto una instancia caída de verdad como una que sigue viva pero colgada por dentro.

Cómo repone el ASG una instancia caída



Vas a provocar esto tú mismo en el reto de la Actividad 4.1: terminar una instancia a mano y cronometrar cuánto tarda el grupo en reponerla.

Periodo de calentamiento: sin él, escalado en espiral


El ASG sigue una política de escalado basada en una métrica: «si la CPU media supera el 70 % durante varios minutos, añade una instancia; si baja del 30 %, quita una».

El periodo de calentamiento existe para esto

Si el ASG evaluara la métrica justo después de lanzar una instancia nueva —que todavía está arrancando, sin servir tráfico— seguiría viendo la CPU alta y lanzaría otra, y otra, hasta la capacidad máxima.

La elasticidad reflejada en la factura

Un ASG no factura una capacidad fija, sino la que realmente está en marcha en cada momento:



El balanceador, en cambio, tiene un coste base fijo por existir más un cargo por tráfico (LCU) — es la pieza no elástica de esta arquitectura.

Ideas clave

- Un ALB reparte tráfico entre instancias de un grupo de destino, comprobando su salud antes de mandarles peticiones; exige al menos dos zonas de disponibilidad.
- Con el balanceador delante, el puerto de la aplicación solo acepta tráfico del grupo de seguridad del propio balanceador.
- El retraso de anulación de registro evita cortes en seco al retirar una instancia.
- Escalado horizontal (más instancias) es la base de la alta disponibilidad; el vertical tiene límite y suele cortar servicio.
- Un ASG combina la comprobación de EC2 y la del grupo de destino para detectar tanto una instancia caída como una colgada por dentro.
- El periodo de calentamiento evita que el ASG escale en espiral. La factura de las instancias sigue la demanda real; el balanceador tiene coste fijo (LCU).